

Powerful data structure and software ecosystem

## 强大的数据结构 Python扩展库

Dazhuang@NJU

Department of Computer Science and Technology

Department of University Basic Computer Teaching

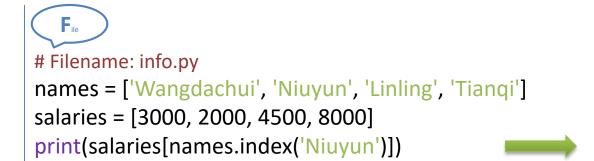
用Python玩转数据

# 为什么需要字典

#### 为什么要使用字典?



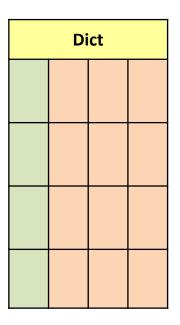
某公司人事部门让技术部门用Python构建一个简易的员工信息表, 包含员工的姓名和工资信息。根据信息表查询员工牛云的工资。



<u>Output</u>: 2000

salaries['Niuyun']

## 字典



#### • 什么是字典?

#### 一种映射类型

- 键 (key)
- 值 (value)
- key-value对

#### 创建字典

Info		
0	'Wangdachui'	
1	'Niuyun',	
2	'Linling'	
3	'Tianqi'	

#### ・ 创建字典

- 直接
- 利用dict函数

cInfo['Niuyun']

```
Source
```

```
>>> aInfo = {'Wangdachui': 3000, 'Niuyun':2000, 'Linling':4500, 'Tianqi':8000}

>>> info = [('Wangdachui',3000), ('Niuyun',2000), ('Linling',4500), ('Tianqi',8000)]

>>> bInfo = dict(info)

>>> cInfo = dict([['Wangdachui',3000], ['Niuyun',2000], ['Linling',4500], ['Tianqi',8000]])

>>> dInfo = dict(Wangdachui=3000, Niuyun=2000, Linling=4500, Tianqi=8000)
```

{'Tianqi': 8000, 'Wangdachui': 3000, 'Linling': 4500, 'Niuyun': 2000}

## 创建字典



#### 创建员工信息表时如何将所有员工的工资默认值设置为3000?



>>> aDict = {}.fromkeys(('Wangdachui', 'Niuyun', 'Linling', 'Tianqi'),3000)

>>> aDict

{'Tianqi': 3000, 'Wangdachui': 3000, 'Niuyun': 3000, 'Linling': 3000}

sorted(aDict) = ?

['Linling', 'Niuyun', 'Tianqi', 'Wangdachui']

### 生成字典



已知有姓名列表和工资列表,如何生成字典类型的员工信息表?



```
>>> names = ['Wangdachui', 'Niuyun', 'Linling', 'Tianqi']
```

>>> salaries = [3000, 2000, 4500, 8000]

>>> dict(zip(names,salaries))

{'Tianqi': 8000, 'Wangdachui': 3000, 'Niuyun': 2000, 'Linling': 4500}

## 生成字典



对于几个公司的财经数据,如何构造公司代码和股票价格的字典?

{'AXP': '78.51', 'BA': '184.76', 'CAT ': '96.39', 'CSCO': '33.71', 'CVX': '106.09'}

## 生成字典

```
# Filename: createdict.py
pList = \cdots
aList = []
bList = []
for i in range(5):
  aStr = pList[i][0]
  bStr = pList[i][2]
  aList.append(aStr)
  bList.append(bStr)
aDict = dict(zip(aList,bList))
print(aDict)
```

```
pList = [('AXP', 'American Express Company', '78.51'),
('BA', 'The Boeing Company', '184.76'),
('CAT', 'Caterpillar Inc.', '96.39'), ···]
```

{'AXP': '78.51', 'BA': '184.76', 'CAT ': '96.39', 'CSCO': '33.71', 'CVX': '106.09'}

用Python玩转数据

# 25

## 字典的使用

#### 字典的基本操作

```
>>> aInfo = {'Wangdachui': 3000, 'Niuyun':2000, 'Linling':4500, 'Tiangi':8000}
>>> aInfo['Niuyun']
                        键值查找
2000
>>> aInfo['Niuyun'] = 9999
>>> aInfo
{'Tianqi': 8000, 'Wangdachui': 3000, 'Linling': 4500, 'Niuyun': 9999}
>>> aInfo['Fuyun'] = 1000 —
>>> aInfo
{'Tiangi': 8000, 'Fuyun': 1000, 'Wangdachui': 3000, 'Linling': 4500, 'Niuyun': 9999}
>>> 'Mayun' in aInfo
False
>>> del aInfo['Fuyun']—
>>> aInfo
{'Tianqi': 8000, 'Wangdachui': 3000, 'Linling': 4500, 'Niuyun': 9999}
```

#### 字典的内建函数

```
dict()
len()
hash()
```

```
>>> names = ['Wangdachui', 'Niuyun', 'Linling', 'Tianqi']
>>> salaries = [3000, 2000, 4500, 8000]
>>> alnfo = dict(zip(names, salaries))
>>> alnfo
{'Wangdachui': 3000, 'Linling': 4500, 'Niuyun': 2000, 'Tianqi': 8000}
>>> len(alnfo)
4
```

#### 字典的内建函数

```
>>> hash('Wangdachui')
7716305958664889313
>>> testList = [1, 2, 3]
>>> hash(testList)
Traceback (most recent call last):
File "<pyshell#127>", line 1, in <module> hash(testList)
TypeError: unhashable type: 'list'
```



已知有员工姓名和工资信息表{'Wangdachui':3000, 'Niuyun':2000, 'Linling':4500, 'Tianqi':8000}, 如何单独输出员工姓名和工资金额?



人事部门有两份人员和工资信息表,第一份是原有信息,第二份是公司中有工资更改人员和新进人员的信息,如何处理可以较快地获得完整的信息表?

```
Source
```

```
>>> aInfo = {'Wangdachui': 3000, 'Niuyun': 2000, 'Linling': 4500} >>> bInfo = {'Wangdachui': 4000, 'Niuyun': 9999, 'Wangzi': 6000}
```

>>> alnfo.update(blnfo)

>>> aInfo

{'Wangzi': 6000, 'Linling': 4500, 'Wangdachui': 4000, 'Niuyun': 9999}



## 下面两个程序都通过键查找值,区别在哪里?你更喜欢哪一个?



>>> stock = {'AXP': 78.51, 'BA': 184.76}

>>> stock['AAA']

Traceback (most recent call last):

File "<stdin>", line 1, in <module>

KeyError: 'AAA'



>>> stock = {'AXP': 78.51, 'BA': 184.76}

>>> print(stock.get('AAA'))

None

#### • 删除字典

```
>>> aStock = {'AXP': 78.51, 'BA':184.76}
>>> bStock = aStock
>>> aStock = {}
>>> bStock
```

{'BA': 184.76, 'AXP': 78.51}

```
>>> aStock = {'AXP': 78.51, 'BA': 184.76}
>>> bStock = aStock
>>> aStock.clear()
>>> aStock
>>> bStock
```

clear()	copy()	fromkeys()	get()	items()	常用 字典
keys()	pop()	setdefault()	update()	values()	方污

#### 字典相关使用小案例

#### ・ JSON格式

- JavaScript Object Notation, JS对象标记)
- 一种轻量级的数据交换格式

#### • 搜索引擎关键词查询

```
百度
http://www.baidu.com/s?wd=%s
谷歌
http://www.googlestable.com/search/?q=%us
Bing
中国: http://cn.bing.com/search?q=%us
```

美国: http://www.bing.com/search?g=%us

## 可变长关键字参数 (字典)

#### Python中函数的参数形式

- 位置或关键字参数
- 仅位置的参数
- 可变长位置参数
- 可变长关键字参数

(参数可以设定默认值)

```
>>> def func(args1, *argst, **argsd):
    print(args1)
    print(argst)
    print(argsd)
>>> func('Hello,','Wangdachui','Niuyun','Linling',a1= 1,a2=2,a3=3)
Hello,
('Wangdachui', 'Niuyun', 'Linling')
{'a1': 1, 'a3': 3, 'a2': 2}
```

用Python玩转数据

3

## 集合

#### 集合

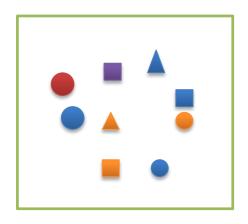


人事部门的一份工资信息表登记时由于工作人员的疏忽有 部分姓名重复登记了,如何快速解决这个问题?



```
>>> names = ['Wangdachui', 'Niuyun', 'Wangzi', 'Wangdachui', 'Linling', 'Niuyun']
>>> namesSet = set(names)
>>> namesSet
{'Wangzi', 'Wangdachui', 'Niuyun', 'Linling'}
```

## 集合



#### ・ 什么是集合?

#### 一个无序不重复的元素的组合

- 可变集合 (set)
- 不可变集合 (frozenset)

#### 集合的创建

```
>>> aSet = set('hello')
>>> aSet
{'h', 'e', 'l', 'o'}
>>> fSet = frozenset('hello')
>>> fSet
frozenset({'h', 'e', 'l', 'o'})
>>> type(aSet)
<class 'set'>
>>> type(fSet)
<class 'frozenset'>
```

## 集合比较



>>> aSet = set('sunrise')

>>> bSet = set('sunset')

>>> 'u' in aSet

#### True

>>> aSet == bSet

#### False

>>> aSet < bSet

#### False

>>> set('sun') < aSet

True

数学符号	Python符号
€	in
∉	not in
=	==
<b>≠</b>	!=
C	<
⊆	<=
⊃	>
⊇	>=

标准类型运算符

## 集合关系运算



```
>>> aSet = set('sunrise')
>>> bSet = set('sunset')
>>> aSet & bSet
{'u', 's', 'e', 'n'}
>>> aSet | bSet
{'e', 'i', 'n', 's', 'r', 'u', 't'}
>>> aSet - bSet
{'i', 'r'}
>>> aSet ^ bSet
{'i', 'r', 't'}
>>> aSet -= set('sun')
>>> aSet
{'e', 'i', 'r'}
```

数学符号	Python符号
Λ	&
U	1
- 或 \	-
Δ	^

集合类型运算符

#### 运算符可复合

#### 集合内建函数

- 函数也能完成以上的任务
  - 面向所有集合

```
s.issubset(t)
issuperset(t)
union(t)
intersection(t)
difference(t)
symmetric_difference(t)
copy()
```

```
>>> aSet = set('sunrise')
>>> bSet = set('sunset')
>>> aSet.issubset(bSet)
False
>>> aSet.intersection(bSet)
{'u', 's', 'e', 'n'}
>>> aSet.difference(bSet)
{'i', 'r'}
>>> cSet = aSet.copy()
>>> cSet
{'s', 'r', 'e', 'i', 'u', 'n'}
```

#### 集合内建函数

- 函数也能完成以上的任务
  - 面向可变集合

```
update(t)
intersection update(t)
difference update(t)
symmetric difference update(t)
add(obj)
remove(obj)
discard(obj)
pop()
clear()
```

```
>>> aSet = set('sunrise')
>>> aSet.add('!')
>>> aSet
{'!', 'e', 'i', 'n', 's', 'r', 'u'}
>>> aSet.remove('!')
>>> aSet
{'e', 'i', 'n', 's', 'r', 'u'}
>>> aSet.update('Yeah')
>>> aSet
{'a', 'e', 'i', 'h', 'n', 's', 'r', 'u', 'Y'}
>>> aSet.clear()
>>> aSet
set()
```

用Python玩转数据



## 扩展库SCIPY

## **SciPy**

#### 特征

- 基于Python的软件生态系统
- 开源
- 主要为数学、科学和工程服务



NumPy
Base N-dimensional array
package



SciPy library Fundamental library for scientific computing



Matplotlib Comprehensive 2D Plotting



IPython
Enhanced Interactive Console



Sympoy
Symbolic mathematics



pandas Data structures & analysis

## Python常用的数据结构



#### 其他数据结构?

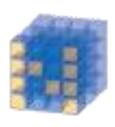


#### · SciPy中的数据结构

Python原有数据结构的变化

- ndarray (N维数组)
- Series (变长字典)
- DataFrame (数据框)

## **NumPy**



#### 特征

- 强大的ndarray对象和ufunc函数
- 精巧的函数
- 比较适合线性代数和随机数处理等科学计算
- 有效的通用多维数据,可定义任意数据类型
- 无缝对接数据库



>>> import numpy as np

>> xArray = np.ones((3,4))

## SciPy库



#### 特征

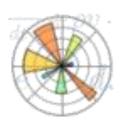
- 基于NumPy,是Python中科学计算程序的核心包,与 NumPy中的函数有交集,但更丰富,有些功能更强
- 有效计算numpy矩阵, 让NumPy和SciPy协同工作
- 致力于科学计算中常见问题的各个工具箱,其不同子模块有不同的应用,如插值、积分、优化和图像处理等

```
Source
```

- >>> import numpy as np
- >>> from scipy import linalg
- >>> arr = np.array([[1,2],[3,4]])
- >>> linalg.det(arr)

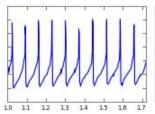
-2.0

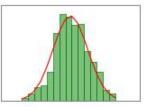
## **Matplotlib**

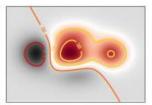


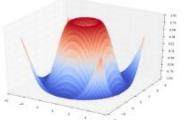
#### 特征

- 基于NumPy
- 二维绘图库,简单快速地生成曲线图、直方图和 散点图等形式的图
- 常用的pyplot是一个简单提供类似MATLAB接口的 模块









## pandas



#### 特征

- 基于 SciPy 和 NumPy
- 高效的Series和DataFrame数据结构
- 强大的可扩展数据操作与分析的Python库
- 高效处理大数据集的切片等功能
- · 提供优化库功能读写多种文件格式,如CSV、HDF5



>>> df[2:5]

>>> df.head(4)

>>> df.tail(3)

用Python玩转数据

# 5

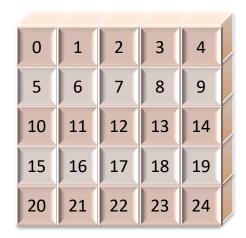
### **NDARRAY**

# Python中的数组

#### 形式

- 用list和tuple等数据结构表示数组
  - ─维数组 list = [1,2,3,4]
  - 二维数组 list = [[1,2,3],[4,5,6],[7,8,9]]
- array模块
  - 通过array函数创建数组, array.array("B", range(5))
  - 提供append、insert和read等方法

## ndarray

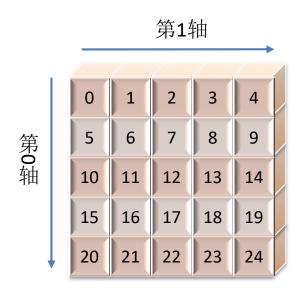


### · ndarray是什么?

#### N维数组

- NumPy中基本的数据结构
- 所有元素是同一种类型
- 别名为array
- 利于节省内存和提高CPU计算 时间
- 有丰富的函数

## ndarray基本概念



#### · ndarray数组属性

#### N维数组

- 维度 (dimensions) 称为轴(axes),轴的个数称为秩 (rank)
- 基本属性
  - ndarray.ndim (秩)
  - ndarray.shape (维度)
  - ndarray.size (元素总个数)
  - ndarray.dtype (元素类型)
  - ndarray.itemsize (元素字节大小)

## ndarray的创建

```
>>> import numpy as np
>>> aArray = np.array([1,2,3])
>>> aArray
array([1, 2, 3])
>> bArray = np.array([(1,2,3),(4,5,6)])
>>> bArray
array([[1, 2, 3],
      [4, 5, 6]])
>>> np.arange(1,5,0.5)
array([ 1., 1.5, 2., 2.5, 3., 3.5, 4., 4.5])
>>> np.random.random((2,2))
array([[ 0.79777004, 0.1468679 ],
   [0.95838379, 0.86106278]])
>>> np.linspace(1, 2, 10, endpoint=False)
array([ 1. , 1.1, 1.2, 1.3, 1.4, 1.5, 1.6, 1.7, 1.8, 1.9])
```

arange	array
сору	empty
empty_like	eye
fromfile	fromfunction
identity	linspace
logspace	mgrid
ogrid	ones
ones_like	r
zeros	zeros_like

ndarray创建函数

## ndarray的创建

```
>>> np.ones([2,3])
array([[ 1., 1., 1.],
   [1., 1., 1.]])
>>> np.zeros((2,2))
array([[ 0., 0.],
       [0., 0.1]
>> np.fromfunction(lambda i,j:(i+1)*(j+1), (9,9))
array([[ 1., 2., 3., 4., 5., 6., 7., 8., 9.],
       [ 2., 4., 6., 8., 10., 12., 14., 16., 18.]
       [ 3., 6., 9., 12., 15., 18., 21., 24., 27.]
       [ 4., 8., 12., 16., 20., 24., 28., 32., 36.],
       [ 5., 10., 15., 20., 25., 30., 35., 40., 45.],
       [ 6., 12., 18., 24., 30., 36., 42., 48., 54.],
       [ 7., 14., 21., 28., 35., 42., 49., 56., 63.],
       [ 8., 16., 24., 32., 40., 48., 56., 64., 72.],
        9., 18., 27., 36., 45., 54., 63., 72., 81.]])
```

arange	array
сору	empty
empty_like	eye
fromfile	fromfunction
identity	linspace
logspace	mgrid
ogrid	ones
ones_like	r
zeros	zeros_like

ndarray创建函数

## ndarray的操作



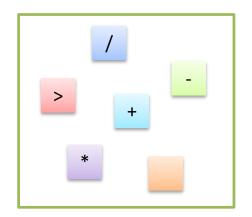
```
>> aArray = np.array([(1,2,3),(4,5,6)])
array([[1, 2, 3],
    [4, 5, 6]]
>>> print(aArray[1])
[4 5 6]
>>> print(aArray[0:2])
[[1 2 3]
[4 5 6]]
>>> print(aArray[:,[0,1]])
[[1 2]
[45]]
>>> print(aArray[1,[0,1]])
[45]
>>> for row in aArray:
         print(row)
[1 2 3]
[4 5 6]
```

# ndarray的操作

```
>> aArray = np.array([(1,2,3),(4,5,6)])
>>> aArray.shape
(2, 3)
>>> bArray = aArray.reshape(3,2)
>>> bArray
array([[1, 2],
       [3, 4],
       [5, 6]])
>>> aArray
array([[1, 2, 3],
       [4, 5, 6]])
```

```
>>> aArray.resize(3,2)
>>> aArray
array([[1, 2],
    [3, 4],
    [5, 6]])
>>> bArray = np.array([1,3,7])
>> cArray = np.array([3,5,8])
>>> np.vstack((bArray, cArray))
array([[1, 3, 7],
    [3, 5, 8]]
>>> np.hstack((bArray, cArray))
array([1, 3, 7, 3, 5, 8])
```

## ndarray的运算



利用基本运算符

```
>> aArray = np.array([(5,5,5),(5,5,5)])
>> bArray = np.array([(2,2,2),(2,2,2)])
>>> cArray = aArray * bArray
>>> cArray
array([[10, 10, 10],
       [10, 10, 10]])
>>> aArray += bArray
>>> aArray
array([[7, 7, 7],
       [7, 7, 7]]
>>> a = np.array([1,2,3])
>> b = np.array([[1,2,3],[4,5,6]])
>>> a + b
array([[2, 4, 6],
      [5, 7, 9]]
```

## ndarray的运算

```
Source
```

```
>> aArray = np.array([(1,2,3),(4,5,6)])
>>> aArray.sum()
21
>>> aArray.sum(axis = 0)
array([5, 7, 9])
>>> aArray.sum(axis = 1)
array([ 6, 15])
>>> aArray.min() # return value
>>> aArray.argmax() # return index
5
>>> aArray.mean()
3.5
>>> aArray.var()
2.916666666666665
>>> aArray.std()
1.707825127659933
```

sum	mean
std	var
min	max
argmin	argmax
cumsum	cumprod

利用基本数组统计方法

# ndarray的专门应用—线性代数

```
Source
>>> import numpy as np
>> x = np.array([[1,2], [3,4]])
>>> r1 = np.linalg.det(x)
>>> print(r1)
-2.0
>> r2 = np.linalg.inv(x)
>>> print(r2)
[[-2. 1.]
[1.5 - 0.5]
>> r3 = np.dot(x, x)
>>> print(r3)
[[ 7 10]
[15 22]]
```

dot	矩阵内积
linalg.det	行列式
linalg.inv	逆矩阵
linalg.solve	多元一次方 程组求根
linalg.eig	求特征值和 特征向量

常用函数示例

## ndarray的ufunc函数

• ufunc (universal function) 是一种能对数组的每个元素 进行操作的函数。NumPy内 置的许多ufunc函数都是在C 语言级别实现的,计算速度 非常快。

add, all, any, arange, apply\_along\_axis, argmax, argmin, argsort, average, bincount, ceil, clip, conj, corrcoef, cov, cross, cumprod, cumsum, diff, dot, exp, floor, ...

```
# Filename: math_numpy.py
import time
import math
import numpy as np
x = np.arange(0, 100, 0.01)
t m1 = time.clock()
for i, t in enumerate(x):
  x[i] = math.pow((math.sin(t)), 2)
t m2 = time.clock()
y = np.arange(0,100,0.01)
t n1 = time.clock()
y = np.power(np.sin(y), 2)
t n2 = time.clock()
print('Running time of math:', t m2 - t m1)
print('Running time of numpy:', t n2 - t n1)
```

用Python玩转数据

**SERIES** 



### **Series**

#### ・ 基本特征

- 类似一维数组的对象
- 由数据和索引组成

```
>>> from pandas import Series
>>> aSer = Series([1,2.0,'a'])
>>> aSer
0  1
1  2
2  a
dtype: object
```

### 自定义Series的index

```
>>> bSer = pd.Series(['apple','peach','lemon'], index = [1,2,3])
>>> bSer
   apple
   peach
  lemon
dtype: object
>>> bSer.index
Int64Index([1, 2, 3], dtype='int64')
>>> bSer.values
array(['apple', 'peach', 'lemon'], dtype=object)
```

### Series的基本运算

```
Source
>>> aSer = pd.Series([3,5,7],index = ['a','b','c'])
>>> aSer['b']
5
>>> aSer * 2
    6
  10
  14
dtype: int64
>>> import numpy as np
>>> np.exp(aSer)
     20.085537
    148.413159
   1096.633158
dtype: float64
```

### Series的数据对齐

```
>>> data = {'AXP':'86.40','CSCO':'122.64','BA':'99.44'}
>>> sindex = ['AXP','CSCO','BA','AAPL']
>>> aSer = pd.Series(data, index = sindex)
>>> aSer
AXP
      86.40
CSCO 122.64
  BA
      99.44
AAPL
      NaN
dtype: object
>>> pd.isnull(aSer)
AXP False
CSCO False
      False
  BA
AAPL
      True
dtype: bool
```

### Series的数据对齐

#### ・重要功能

在算术运算中自 动对齐不同索引 的数据

```
Source
>>> aSer = pd.Series(data, index = sindex)
>>> aSer
AXP
      86.40
CSCO 122.64
      99.44
  BA
AAPL
           NaN
dtype: object
>>> bSer = {'AXP':'86.40','CSCO':'122.64','CVX':'23.78'}
>>> cSer = pd.Series(bSer)
>>> aSer + cSer
AAPL
                NaN
 AXP 86.4086.40
  BA
               NaN
CSCO 122.64122.64
 CVX
                NaN
dtype: object
```

## Series的name属性

#### ・重要功能

- Series对象本身及 其索引均有一个 name属性
- Series的name属性 与其他重要功能关 系密切

```
>>> aSer = pd.Series(data, index = sindex)
>>> aSer.name = 'cnames'
>>> aSer.index.name = 'volume'
>>> aSer
volume

AXP 86.40
CSCO 122.64
BA 99.44
AAPL NaN
```

Name: cnames, dtype: object

用Python玩转数据



### **DATAFRAME**

### **DataFrame**

#### ・ 基本特征

- 一个表格型的数据结构
- 含有一组有序的列 (类似于index)
- 大致可看成共享同一个index的Series集合

### DataFrame的索引和值

```
Source
>>> data = np.array([('Wangdachui', 4000), ('Linling', 5000), ('Niuyun', 6000)])
>>> frame =pd.DataFrame(data, index = range(1, 4), columns = ['name', 'pay'])
>>> frame
         name
                  pay
1 Wangdachui
                4000
                5000
        Linling
        Niuyun 6000
>>> frame.index
RangeIndex(start=1, stop=4, step=1)
>>> frame.columns
Index(['name', 'pay'], dtype='object')
>>> frame.values
array([['Wangdachui', '4000'],
    ['Linling', '5000'],
    ['Niuyun', '6000']], dtype=object)
```

### DataFrame的基本操作

• 取DataFrame对象的列和行可获 得Series



>>> frame['name']

0 Wangdachui

1 Linling

2 Niuyun

Name: name, dtype: object

>>> frame.pay

0 4000

1 5000

2 6000

Name: pay, dtype: int64

```
name pay
0 Wangdachui 4000
1 Linling 5000
2 Niuyun 6000
```



>>> frame.iloc[ : 2, 1]

0 4000

1 5000

Name: pay, dtype: object

### DataFrame的基本操作

• DataFrame对象的修改和删除

```
Source
```

```
>>> frame['name'] = 'admin'
```

>>> frame

name pay

0 admin 4000

1 admin 5000

2 admin 6000

```
Source
```

>>> del frame['pay']

>>> frame

name

0 admin

1 admin

2 admin

[3 rows x 1 columns]

### DataFrame的统计功能

• DataFrame对象成员找最低工资和高工资人群信息

	name	pay
0	Wangdachui	4000
1	Linling	5000
2	Niuyun	6000





>>> frame[frame.pay >= '5000']

name pay

- 1 Linling 5000
- 2 Niuyun 6000